Информационный поиск

Константин Мосиенко

Yandex School of Data Analysis *konstantin.mosienko@gmail.com*

2017

Содержание

1. Введение
2. Модели поиска
   - Простые модели
   - Обобщенная векторная модель
   - Latent Semantic Indexing
3. Языковые модели, лингвистика и NLP
   - Языковые модели. Простые закономерности
   - N-граммная языковая модель
   - Сглаживание

Введение

Литература

- C.D. Manning, P. Raghavan, H. Schutze. Introduction to Information Retrieval [2008]
- B. Croft, D. Metzler, T. Strohman. Search Engines: Information Retrieval in Practice [2009]
- S. Buttcher, C. L. A. Clarke and G. V. Cormack. Information Retrieval: Implementing and Evaluating Search Engines [2010]
- https://en.wikipedia.org/wiki/Information_retrieval

Конференции

- TREC (Text Retrieval Conference)
- CLEF (Cross Language Evaluation Forum)
- WWW (World Wide Web Conference)
- ESSIR (European Summer School in Information Retrieval)
- SIGIR (Special Interest Group on Information Retrieval)
- WSDM (Web Search and Data Mining)
- CIKM (Conference on Information and Knowledge Management)

Определение

Определение

Информационный поиск – это область научных исследований, ориентированная на изучение структуры, организации, хранения, поиска и извлечения информации. [G. Salton, 1968]

Определение

Информационный поиск — процесс поиска неструктурированной документальной информации, удовлетворяющей информационные потребности, и наука об этом поиске. [C. Manning, 2011]

Мы будем рассматривать вопросы, касающиеся поиска по интернет сайтам.

Запрос - документ

Определение

Документ - это информационная сущность, которая хранится в базе поисковой системы (индексе). Процесс занесения документа в индекс - индексация. Документом могут быть: локальные файлы различных форматов, html-страницы, видео, аудио, картинки.

Определение

Запрос - способ выражения информационных потребностей. Обычно запрос задаётся с помощью языка запросов соответствующей поисковой системы.

Что умеет поисковая система

- Находить и скачивать документы.
- Детектировать язык и кодировку. Извлекать информацию из документов различных форматов.
- Оценивать частоту обновления документа.
- Находить в своей базе похожие документы и спам.
- Быстро отвечать на запросы к своему индексу.
- Ранжировать результаты поиска по релевантности.

Определение

Релевантность - семантическое соответствие поискового запроса и найденного документа.

Два поиска

Слово «поиск» может употребляться в контексте разных задач:

- Поиск в имеющейся базе. Например, поиск релевантных запросу документов в индексе поисковой системы. Базовая операция - перечисление документов, содержащих определённое слово(словосочетание).
- Обнаружение кандидатов на занесение в индекс. Например, поиск в интернете отсутствующих в индексе(новых) документов. Базовая операция - перечисление документов, на которые есть ссылки с имеющегося документа.

Некоторые особенности и сложности

- Информация доступна в неструктурированном с точки зрения индексирования виде: например, как понять, где на странице важный текст, а где рекламный блок?
- Пользователь не всегда ищет текст, он может искать и видео.
- Актуальность. Необходимо иметь как можно более точный «слепок» интернета. Быстро находить новую информацию и не забывать удалять не актуальную.
- Региональность. Один запрос, заданный из разных мест, иногда должен приводить к разным результатам. Например, если вы заказываете пиццу.

Базовые компоненты

- Поисковый робот. Скачивает документы из интернета, обнаруживает новые документы, планирует очередь скачки(так как обычно нет возможности скачать все известные документы, необходимо сделать выбор, какие обойти сейчас, а какие, может быть, никогда).
- Индексатор. Обрабатывает скаченные документы, строит поисковый индекс.
- Поиск. Отвечает на запросы пользователей, генерирует статистику.

Масштабы трагедии

Абсолютные показатели различных экспериментов не совпадают, поэтому необходимо смотреть на отношения.

- Согласно косвенным показателям, количество страниц, доступных для индексирования, в 2005 году составляло 11.5 миллиарда, в 2009 году - 25 миллиардов.
- В соответствии с исследованиями 2001-го года, большая часть документов интернета - 550 миллиардов - не обнаружена поисковыми системами, эту часть называют DeepWeb.
- В 2008 году Google знал 1 триллион уникальных URL-ов.

Так как нет возможности положить в индекс такое количество документов, современная поисковая система производит поиск по десяткам-сотням миллиардов документов.

Uniform Resource Locator

scheme:[//[user:password@]host[:port]][/]path[?query][#fragment]

Один URL можно записать разными способами:

- Схема и имя хоста не чувствительны к регистру.
- Можно не писать стандартный порт.
- Вместо символа можно написать его код через %

HTTP

GET /index.html HTTP/1.1
Host: www.example.com

HTTP/1.1 200 OK
Date: Mon, 23 May 2005 22:38:34
Content-Type: text/html;
charset=UTF-8
Content-Encoding: UTF-8
Content-Length: 138
Last-Modified: Wed, 08 Jan 2003
23:11:55 GMT
...

HTML

```
<!DOCTYPE html>
<html>
  <head>
    <meta http-equiv="Content-Type" content="text/html;
charset=utf-8" />
    <title>HTML Document</title>
  </head>
  <body>
    <p>
      <b>
        Этот текст будет полужирным,
        <i>а этот — ещё и курсивным</i>
      </b>
    </p>
  </body>
</html>
```

Инвертированный индекс

Определение

Инвертированный индекс - это структура данных, хранящая для каждого слова список документов, в которых это слово встречается.
Постинг лист - вышеупомянутый список документов.

В инвертированном индексе можно ещё хранить и удобно получать доступ к таким данным:

- Свойства самого слова. Например, число его вхождений в корпус.
- Свойства слова и документа. Например, число вхождений слова в документ.

Постинг листы обычно хранят отсортированными по идентификатору документа для ускорения поиска.

Модели поиска

Булев поиск

Определение

Булев поиск - первая и самая простая модель информационного поиска. Основывается на выполнении теоретико-множественных операций над списками документов в соответствии с запросом.

- Пусть дан запрос вида $q = (t_1|t_2)\&t_3\ldots$
- На первом шаге необходимо для каждого терма запроса t_i с помощью инвертированного индекса получить список документов, содержащих этот терм.
- На втором шаге необходимо выполнить указанные в запросе операции с полученными множествами документов.

Недостатки булева поиска

- Находит только документы, точно соответствующие запросу. Например, для запроса $q = t_1 \& t_2$ если какой-то документ содержит только терм t_1, он не найдётся даже если остальные документы не содержат ни одного слова из запроса.
- Не ранжирует результаты поиска.
- Все слова для поиска имеют одинаковую важность, что не соответствует действительности.

Расширенный булев поиск

Недостатки простого булева поиска можно устранить введя в рассмотрение веса термов и модифицировав процедуру поиска:

- $q = \{(t_1, w_{q1}), ..., (t_n, w_{qn})\}$ - термы запроса со своими весами.
- $d = \{..., (t_1, w_{d1}), ..., (t_n, w_{dn}), ...\}$ - вхождения термов запроса в документ, веса соответствующих термов относительно документа.

Замечания:

- Схема выставления весов не является частью модели.
- $w_{\{q|d\}i} \in [0, 1]$
- Документ может и не содержать определённые термы запроса, для таких термов $w_{di} = 0$.

Расширенный булев поиск

Предлагается от простого отношения «слово запроса входит в документ» перейти к учёту весов термов для построения метрики «близости» запроса и документа:

- $sim(d, q = t_1 \& \ldots \& t_n) =$
  $1 - \left(\sum_{i=1}^{n} w_{qi}^{p}(1 - w_{di})^{p}\right)^{\frac{1}{p}} \left(\sum_{i=1}^{n} w_{qi}^{p}\right)^{-\frac{1}{p}}$
- $sim(d, q = t_1 | \ldots | t_n) = \left(\sum_{i=1}^{n} w_{qi}^{p} w_{di}^{p}\right)^{\frac{1}{p}} \left(\sum_{i=1}^{n} w_{qi}^{p}\right)^{-\frac{1}{p}}$

Замечания:

- p - параметр модели и требует подбора.
- Указанные формулы необходимо рекурсивно применять в соответствии с разбором запроса на элементарные булевы функции, используя в качестве веса для некоторой подформулы значение функции *sim* на ней.

Векторная модель документа

- Документы и запросы представляются в виде разреженных векторов размерности $|T|$ (размер словаря, количество термов):

$$d_i = \{w_{d_i1}, w_{d_i2}, ..., w_{d_i|T|}\}$$

$$q = \{w_{q1}, w_{q2}, ..., w_{q|T|}\}$$

- Каждая компонента вектора соответствует появлению определённого терма: если w_{d_ij} отличен от нуля, значит терм t_j встретился в документе d_i.
- Метрика схожести документа и запроса(или другого документа) - косинус угла между их векторными представлениями.

Векторная модель документа

Замечания

- На веса никакие ограничения не накладываются.

Плюсы (относится и к расширенному булевому поиску)

- Учитывает веса слов.
- Допускает отсутствия слов запроса в документе.
- Позволяет ранжировать результаты.

Недостатки (относится и к расширенному булевому поиску)

- Модель подразумевает, что слова появляются в тексте независимо.
- Не учитывается порядок слов.
- Не учитывается смысл документа - если важное слово заменить на синоним, документ может перестать быть релевантным с точки зрения модели.

Расчёт весов термов

Веса термов влияют на разные метрики близости документов.

- Чем больше вес - тем больше вклад в метрику.
- Поэтому хочется давать большой вес «важным» словам.

Как понять, что слово важное?

- Если слово запроса часто встречается в документе, стоит считать его важным.
- Если только это слово не встречается часто во всех документах.

Учтя вышесказанное, возьмём в рассмотрение следующие характеристики:

- Частота терма в документе (tf).
- Доля документов с данным термом (df).

Term Frequency

$f_{t,d}$ - количество вхождений терма t в документ d. $|d|$ - общее количество термов в документе. $tf(t,d)$ - способ придать терму вес относительно данного документа. Возможны варианты:

- $tf(t,d) = \{0,1\}$ (входит / не входит).
- $tf(t,d) = f_{t,d}$.
- $tf(t,d) = f_{t,d}/|d|$, $tf(t,d) = f_{t,d}/max_{t' \in d} f_{t',d}$.
- $tf(t,d) = 1 + log(f_{t,d})$.
- $tf(t,d) = K + (1-K) f_{t,d}/max_{t' \in d} f_{t',d}$, $K \in [0,1)$.

Выбор конкретной схемы зависит от задачи, например, для расширенного булева поиска необходимы веса из $[0,1]$.

Inverse Document Frequency

$|D|$ - общее количество документов в коллекции D (корпусе). n_t - количество документов, в которых встретился терм t. $idf(t)$ - способ придать вес терму относительно всей коллекции документов, указывающий на количество информации, которое несёт появление терма:

- $idf(t) = \log \frac{|D|}{n_t}$.
- $idf(t) = \log \frac{|D|}{n_t+1}$.
- $idf(t) = \log \frac{max_{t' \in d} n_{t'}}{n_t+1}$.
- $idf(t) = idf(t)/max_{t' \in d} idf(t')$.

TF-IDF

$$tfidf(t, d) = tf(t, d) idf(t)$$

- С одной стороны, компонент $tf(t, d)$ увеличивает вес с увеличением количества вхождений терма в документ.
- С другой стороны, компонент $idf(t)$ стремится к нулю при увеличении доли документов, в которых встретился терм.
- $tfidf(t, d)$ максимален для самого частотного терма t, который встречается только в документе d. Можно считать, что такой терм идеально характеризует свой документ.

Вероятностная модель

В основе модели лежит попытка вероятностно-статистически обосновать понятие релевантности документа запросу и вычислить вероятность того, что пользователь оценит данный документ как релевантный. Воспользовавшись Байесовскими правилами, можно сделать следующие выводы:

- Если $P(R = 1|D) > P(R = 0|D)$, можно считать документ D релевантным.
- $P(R|D) = P(D|R)P(R)/P(D)$.

Все вычисления произведены в условиях наличия некоторого запроса. Проблемой является вычисление вероятностей $P(D|R)$.

Бинарная модель независимости

- С целью сделать $P(D|R)$ вычислимой на практике, предполагается независимость появления термов в документе: $P(D = d|R) = \prod_{i=1}^{|d|} P(t_i|R)$.
- Изначально этот результат использовался для выставления весов термов для векторной модели:

$$w_i = \log \frac{p_i(1 - u_i)}{u_i(1 - p_i)}$$

Где p_i - вероятность встретить терм t_i в релевантном документе, а u_i - в нерелевантном.

Бинарная модель независимости

Теперь проблемой является вычисление $p_i = P(t_i|R = 1)$ и $u_i = P(t_i|R = 0)$. Подход к решению данной проблемы зависит от доступных данных:

- Если на этапе настройки для каждого запроса есть список релевантных документов, можно явно оценить вероятности через частоты с учётом независимости термов.
- Если имеется информация о том, какие документы релевантны некоторым запросам (не известно каким), то можно считать, что распределения термов различаются только между релевантными/нерелевантными документами.
- Если ничего не известно, то можно самим попытаться восстановить множество релевантных документов, например, более строгой моделью поиска.
- ...

Okapi BM25

$$sim(d,q) = \sum_{i=0}^{|q|} idf(t_i) \frac{tf(t_i,d)(k+1)}{tf(t_i,d) + k((1-b) + b\frac{|d|}{average|d_j|, d_j \in D})}$$

- Okapi - поисковая система, созданная в Лондонском городском университете. BM - best match.
- k и b - подбираемые параметры.
- По сей день может использоваться как фактор для более сложных функций ранжирования.

Обобщенная векторная модель

Одним из недостатков векторной модели является предположение о независимости термов. В статье[1] предлагается один из вариантов устранения этого недостатка. Для удобства будем пользоваться обозначениями, введёнными авторами:

- $D = \{\overline{d}_\alpha\}, \alpha = 1, ..., p$ - коллекция документов.
- $\overline{q}$ - запрос
- $\{\overline{t}_i\}, i = 1, ..., n$ - нормированные, но в общем случае не ортогональные, векторы, соответствующие термам t_i.

[1] Wong, S. K. M.; Ziarko, Wojciech; Wong, Patrick C. N. (1985), Generalized vector spaces model in information retrieval

Обобщенная векторная модель

В соответствии с векторной моделью документа и учтя, что векторы термов не ортогональны, а мера схожести - скалярное произведение, можно записать:

- $\overline{d}_\alpha = \sum_{i=1}^{n} a_{\alpha i}\overline{t}_i$, $\overline{q} = \sum_{j=1}^{n} q_j\overline{t}_j$ - разложение документа и запроса по векторам $\{\overline{t}_i\}$.
- $sim(\overline{d}_\alpha, \overline{q}) = \sum_{i=1}^{n} \sum_{j=1}^{n} a_{\alpha i} q_j \; \overline{t}_i \cdot \overline{t}_j$ - их скалярное произведение.

Для вычисления меры схожести нет необходимости знать непосредственное представление для $\{\overline{t}_i\}$, необходимы лишь попарные скалярные произведения. Обратим внимание, что пространство, в котором лежат $\{\overline{t}_i\}$ может быть произвольной размерности.

Обобщенная векторная модель

Отличия обобщённой векторной модели от обыкновенной:

- Отказ от конкретного описания пространства, в котором лежат векторы термов $\{\bar{t}_i\}$. При решении конкретной задачи, такое пространство будет введено явно или неявно, но только для вычисления $\bar{t}_i \cdot \bar{t}_j$.
- Отказ от предположения о независимости термов.

Данные решения усложнили вычисление меры схожести запроса и документа, так как теперь требуются скалярные произведения $\bar{t}_i \cdot \bar{t}_j$, которые раньше выпадали из вычислений из-за независимости термов.
Следующий шаг - привести пример построения скалярного произведения $\bar{t}_i \cdot \bar{t}_j$, обладая только данными из обыкновенной векторной модели.

Обобщенная векторная модель

В качестве $\overline{t}_i \cdot \overline{t}_j$ можно воспользоваться нормализованной поточечной взаимной информацией NPMI[2]. Если X и Y - дискретные случайные величины, а $P(X = x) = p(x)$, то

$$PMI(x, y) = \log_2 \frac{p(x, y)}{p(x)p(y)} = \log_2 p(x, y) - \log_2 p(x) - \log_2 p(y)$$

$$NPMI(x, y) = PMI(x, y)/(-\log_2 p(x, y))$$

$NPMI(x, y) \in [-1, 1]$ и обладает следующими своствами:

- $NPMI(x, y) = -1$ для несовместных событий.
- $NPMI(x, y) = 0$ для событий, появляющихся независимо.
- $NPMI(x, y) = 1$ для событий, которые появляются только вместе.

[2] Bouma, Gerlof (2009). Normalized (Pointwise) Mutual Information in Collocation Extraction

Обобщенная векторная модель

Создатели модели предлагают и свой подход. Начнём с простого примера. Пусть у нас есть коллекция документов D, в которой документы состоят только из двух термов t_1 и t_2.

- $D = D_{t_1,-t_2} \sqcup D_{t_1,t_2} \sqcup D_{-t_1,t_2}$ - разбиение D на подмножества в соответствии с наличием/отсутствием соответствующего терма.
- Интуиция подсказывает:
  - $|D_{t_1,t_2}|$ должна быть непосредственно связана с $\bar{t}_i \cdot \bar{t}_j$.
  - Вектор $\bar{t}_1$ должен быть суммой вкладов от $D_{t_1,-t_2}$ и D_{t_1,t_2} (симметрично и для $\bar{t}_2$). Это предположение является неявным вводом пространства для $\{\bar{t}_i\}$, источником независимости и попыткой получить как можно больше информации от обыкновенной векторной модели.

Обобщенная векторная модель

В соответствии с интуитивными предположениями запишем:

$$\overline{t}_1 = \frac{|D_{t_1,-t_2}|\overline{m}_1 + |D_{t_1,t_2}|\overline{m}_2}{\sqrt{|D_{t_1,-t_2}|^2 + |D_{t_1,t_2}|^2}} \quad \overline{t}_2 = \frac{|D_{t_1,t_2}|\overline{m}_2 + |D_{-t_1,t_2}|\overline{m}_3}{\sqrt{|D_{t_1,t_2}|^2 + |D_{-t_1,t_2}|^2}}$$

$$\overline{t}_1 \cdot \overline{t}_2 = \frac{|D_{t_1,t_2}|^2}{\sqrt{|D_{t_1,-t_2}|^2 + |D_{t_1,t_2}|^2}\sqrt{|D_{t_1,t_2}|^2 + |D_{-t_1,t_2}|^2}}$$

Где $\{\overline{m}_1, \overline{m}_2, \overline{m}_3\}$ - некоторый ортонормированный базис. Каждый вектор $\overline{m}_i$ отвечает некоторому максимальному по размеру подмножеству документов с одинаковой «маской» вхождения/невхождения термов.

Обобщенная векторная модель

Усложним ситуацию. Пусть теперь:

$$D = D_{t_1,t_2,t_3} \sqcup D_{-t_1,t_2,t_3} \sqcup \ldots \sqcup D_{-t_1,t_2,-t_3} \sqcup D_{-t_1,-t_2,t_3}$$

Теперь у t_1 (как и у остальных) больше способов войти в документ относительно наличия остальных термов:

$$\bar{t}_1 = \frac{1}{N_1}(|D_{t_1,t_2,t_3}|\overline{m}_1 + |D_{t_1,-t_2,t_3}|\overline{m}_3 + |D_{t_1,t_2,-t_3}|\overline{m}_4 + |D_{t_1,-t_2,-t_3}|\overline{m}_5)$$

$$N_1 = \sqrt{|D_{t_1,t_2,t_3}|^2 + |D_{t_1,-t_2,t_3}|^2 + |D_{t_1,t_2,-t_3}|^2 + |D_{t_1,-t_2,-t_3}|^2}$$

$$\ldots$$

Выражение для скалярного произведения примет вид:

$$\bar{t}_1 \cdot \bar{t}_2 = \frac{1}{N_1 N_2}(|D_{t_1,t_2,t_3}|^2 + |D_{t_1,t_2,-t_3}|^2)$$

Обобщенная векторная модель

Для упрощения записи формул случая общего вида воспользуемся обозначениями из булевой алгебры.

- Пусть $m_k = t_1^{\delta_1} \wedge \ldots \wedge t_n^{\delta_n}$ - некоторый элемент булевой алгебры, отвечающий вектору $\overline{m}_k$. Где

$$t_i^{\delta_i} = \begin{cases} t_i & \text{если } \delta_i = 1 \\ \neg t_i & \text{иначе} \end{cases}$$

  обозначает наличие или отсутствие соответствующего терма в документе.
- Каждый элемент t_i может быть представлен в виде $t_i = m_{i_1} \vee \ldots \vee m_{i_r}$, где операция производится над всеми такими m_{i_j}, для которых $m_{i_j} \vee t_i = t_i$.
- В соответствии с предыдущим пунктом: $\overline{t}_i = \sum_{j=1}^{r} c_j(t_i)\overline{m}_{i_j}$

Обобщенная векторная модель

Стоит сделать несколько замечаний:

- $\{\overline{m}_1, \ldots, \overline{m}_{2^n}\}$ - как было сказано выше, произвольный ортонормированный базис. В явном виде эти векторы при вычислениях никогда не появляются.
- Как вычислять $c_j(t_i)$? Возможны несколько вариантов:
  - Положить $c_j(t_i) = 1$. Самый простой случай, соответствует обычному булеву поиску (не в прямом смысле).
  - Вычислять $c_j(t_i)$ как было предложено при рассмотрении простых примеров.
  - Попытаться обобщить предыдущий вариант и воспользоваться изначальным векторным представлением документов.

Обобщенная векторная модель

Воспользуемся весами термов $a_{\alpha i}$ из обыкновенной векторной модели для подсчёта $c_j(t_i)$.

- Пусть для каждого $m_k = t_1^{\delta_1} \wedge \ldots \wedge t_n^{\delta_n}$:

$$D(m_k) = D_{t_1}^{\delta_1} \cap \ldots \cap D_{t_n}^{\delta_n}$$

$$D_{t_i}^{\delta_i} = \begin{cases} D_{t_i} & \text{если } \delta_i = 1 \\ D_{-t_i} & \text{иначе} \end{cases}$$

- Тогда $c_j(t_i) = \sum_{\{\alpha : d_\alpha \in D(m_{i_j})\}} a_{\alpha i}$ и если необходимо занормировать $\overline{t}_i$:

$$\overline{t}_i = \frac{1}{N_i} \sum_{j=1}^{r} c_j(t_i) \overline{m}_{i_j} \quad N_i = \sqrt{\sum_{j=1}^{r} c_j^2(t_i)}$$

Обобщенная векторная модель

Достоинства обобщённой векторной модели:

- Отказ от изначально неверного предположения о независимости термов, что даёт более точную меру схожести.

Недостатки:

- Сложна для вычисления, требует хранить матрицу скалярных произведений.
- Не учитывает порядок термов (можно исправить с помощью n-граммного индекса).

Latent Semantic Indexing

Как уже было сказано выше, проблемами векторной модели являются:

- Предположение о независимости термов.
- Синонимы. Одинаковый смысл может быть передан разными словами.
- Многозначные слова, имеющие разный смысл в зависимости от контекста.

LSI[3] была разработана с учётом всех этих недостатков.

[3] Deerwester, S., et al, Improving Information Retrieval with Latent Semantic Indexing. (1988)

Latent Semantic Indexing

- Идея (Deerwester et al):
  "We would like a representation in which a set of terms, which by itself is incomplete and unreliable evidence of the relevance of a given document, is replaced by some other set of entities which are more reliable indicants. We take advantage of the implicit higher-order (or latent) structure in the association of terms and documents to reveal such relationships."
- Будем полагаться на принцип: чем чаще два слова встречаются в похожих контекстах, тем ближе они по смыслу.

Latent Semantic Indexing

Важно учитывать, что подразумевается под «контекстом»:

- Word2Vec - несколько слов перед и после текущей позиции.
- LSI - факт появления в одном документе.

LSI заключается в переходе из исходного пространства классической векторной модели в пространство меньшей размерности. Данный переход можно осуществить с помощью *SVD*. Для вычислений по модели LSI достаточно матрицы *терм-документ*.

Latent Semantic Indexing

Последовательность шагов:

- Построить матрицу *терм-документ* $A = \{a_{ij} = tf_{ij}\}$ (где каждому терму соответствует строка, а документу - столбец), заполненную частотами термов.
- Отнормировать матрицу A следующим образом (можно и другими способами):

$$\hat{a}_{ij} = g_i \log(a_{ij} + 1), \quad g_i = \sum_{j=1}^{|D|} \frac{p_{ij} \log p_{ij}}{\log |D|}, \quad p_{ij} = \frac{tf_{ij}}{\sum_{k=1}^{|D|} tf_{ik}}$$

(чтобы понять, окуда столько логарифмов, следует обратиться к преобразованию Бокса-Кокса. *SVD* предполагает нормальность данных, а частоты слов далеко не нормальны - они подчиняются закону Ципфа)

Latent Semantic Indexing

Последовательность шагов:

- С помощью *SVD*(Truncated *SVD*) построить разложение $\hat{A} \approx TSD^T$ с r наибольшими сингулярными числами. Представление документа во внутреннем r-мерном пространстве и есть искомое представление. Каждая компонента в нём - соответствие некоторой «тематике».
- Для необходимых документов выполнить преобразование $d_{LSI} = d^T TS^{-1}$, где d - столбец $\hat{A}$ или соответствующим образом преобразованный запрос в формате векторной модели.
- Выполнить сравнения с помощью скалярного произведения в r-мерном пространстве.

Latent Semantic Indexing

Достоинства модели:

- Учитывает зависимость появления термов, наличие синонимии и нескольких смыслов у слов.

Недостатки:

- Вычислительная сложность при построении модели.
- Вычислительная сложность при поиске - необходимо сравнить запрос с каждым документом в коллекции.

Языковые модели, лингвистика и NLP

Языковые модели. Мотивация

Определение

Языковая модель - это вероятностное распределение на последовательностях термов.

В большинстве задач информационного поиска необходимо вычислять вероятность появления заданной последовательности слов или символов. Мы уже убедились, что это необходимо как минимум для построения адекватной меры схожести запросов и документов.
Но необходимость в языковой модели может появиться уже раньше: в языке может не быть выделенной границы между словами, или, например, могут опускаться гласные.

Языковые модели. Мотивация

Другие применения языковой модели:

- Порождение текста - генеративная модель языка.
- Распознавание речи. Необходимо определить, какая из интерпретаций фразы наиболее вероятна.
- Категоризация текстов. Модель может быть построена не по всему языку, а например, только по научным статьям.

Рассмотрим некоторые простые закономерности, которые могут быть полезны при работе с текстом.

Простые закономерности. Zipf Law

На практике часто оказывается, что некоторые характеристики исследуемых объектов, такие как частота (появления) или размер (группы), подчиняются одному закону - закону Ципфа, который связывает вероятность появления объекта с его рангом k в списке, отсортированном по некоторому параметру:

$$f(k; s, N) = \frac{1/k^s}{\sum_{n=1}^{N} 1/n^s}$$

Здесь s - параметр модели. Простыми словами: количество объектов, находящихся в списке на позиции k, обратно пропорционально k в некоторой степени s.

Простые закономерности. Zipf Law

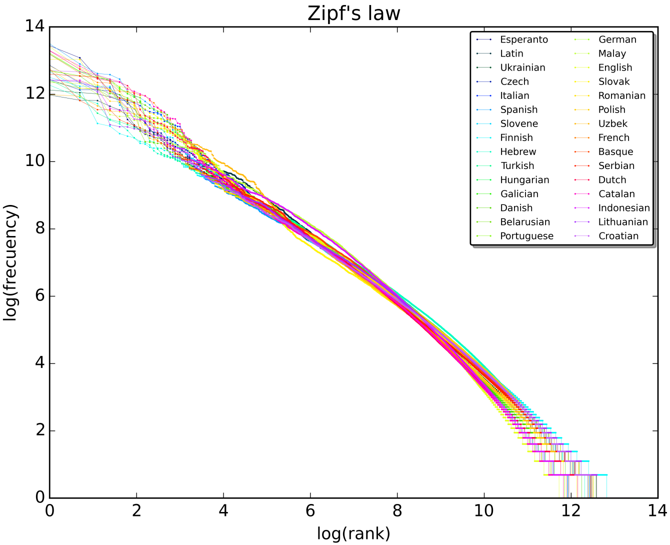

Простые закономерности. Zipf Law

Закону Ципфа подчиняются:

- Частоты слов в большинстве языков (даже искусственных).
- Размеры городов. Размеры корпораций.
- Прибыль, зарплаты.
- Аудитории телеканалов.
- Размеры групп похожих документов в интернете.

Простые закономерности. Heaps' Law

Другой полезный закон - Heaps' law, связан с увеличением словаря при добавлении новых документов. Его также называют Herdan's law. Закон выражает размер словаря как функцию от количества документов:

$$|T| = K|D|^{\beta}$$

Здесь β - параметр модели.
Также, как и закон Ципфа, данный закон применим не только к словарю термов коллекции документов.

Простые закономерности. Zipf Law

Примерная зависимость количества слов от размера текста:

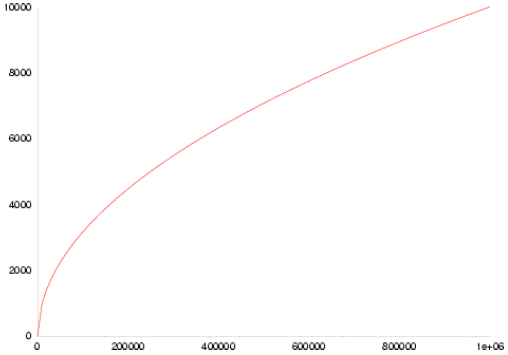

Униграммная модель языка

Самая простая модель, для вычисления вероятности последовательности термов использует только маргинальные вероятности:

$$P(t_1 t_2 t_3) = P(t_1)P(t_2|t_1)P(t_3|t_1 t_2)$$

$$P_{1-gramm}(t_1 t_2 t_3) \approx P(t_1)P(t_2)P(t_3)$$

Знак $\approx$ в данном случае не означает примерное совпадение, он лишь указывает на способ приближения. Данная модель применялась нами ранее в простых моделях поиска.

N-граммная модель языка

Недостатки униграммной модели очевидны. Для построения более правдоподобной модели необходимо учитывать контекст:

$$P(t_1 t_2 t_3 t_4) = P(t_1)P(t_2|t_1)P(t_3|t_1 t_2)P(t_4|t_1 t_2 t_3)$$

$$P_{2-gramm}(t_1 t_2 t_3 t_4) \approx P(t_1)P(t_2|t_1)P(t_3|t_2)P(t_4|t_3)$$

$$P_{3-gramm}(t_1 t_2 t_3 t_4) \approx P(t_1)P(t_2|t_1)P(t_3|t_1 t_2)P(t_4|t_2 t_3)$$

$$P_{n-gramm}(t_1 \dots t_m) \approx \prod_{i=1}^{m} P(t_i|t_{i-(n-1)} \dots t_{i-1})$$

Здесь $P(t_i|t_{i-1})$ означает вероятность встретить терм t_i после t_{i-1}. Следует заметить, что отдельный интерес могут представлять и сами вероятности $P(t_i|t_{i-(n-1)} \dots t_{i-1})$ - вероятности встретить слово в текущем контексте.

N-граммная модель языка. Skip-gram

Для некоторых задач, в которых необходимо, например, учесть и левый и правый контекст слова или снизить влияние перестановок рядом стоящих слов, можно воспользоваться подходом k-skip-n-gram.

Определение

k-skip-n-gram - подпоследовательность исходного текста, обладающая длиной k, в которой каждый терм находится в тексте на расстоянии, не большем, чем n.

N-граммная модель языка. Сглаживание

Для работы с n-граммными моделями (и другими, основанными на умножении вероятностей) необходимо знать условные вероятности появления термов, например, для биграммной модели: $P(t_i|t_{i-1}) = c(t_{i-1}t_i)/\sum_j c(t_{i-1}t_j)$.
Если в тексте, для которого вычисляется вероятность, встречается новое для модели слово, итоговая вероятность $P_{n-gramm}(t_1 ... t_m)$ будет равна нулю. Это, обычно, не то, что требуется.
Самая простая идея, «add-one smoothing»:

$$P(t_i|t_{i-1}) = \frac{1 + c(t_{i-1}t_i)}{|T| + \sum_j c(t_{i-1}t_j)}$$

В дальнейшем будем рассматривать методы сглаживания на примере биграммной модели.

Сглаживание: Additive

Будем считать, что мы «видели» каждую n-грамму на δ раз больше, чем на самом деле:

$$P_{add}(t_i|t_{i-1}) = \frac{\delta + c(t_{i-1}t_i)}{\delta|T| + \sum_j c(t_{i-1}t_j)}$$

Обычно выбирают $0 < \delta \leq 1$.
Это один из самых простых методов, но он достаточно не точный.

Сглаживание: Good-Turing estimation

- Предположим, некоторая n-грамма α появляется в корпусе с некоторой неизвестной вероятностью p.
- Допустим, что все вхождения α в корпус независимы, а количество вхождений подчинено биномиальному распределению:

$$P(c(\alpha) = r) = C_N^r p^r (1-p)^{N-r}$$

- Для построения модели нам необходимо найти ожидаемое количество вхождений:

$$E_N[c^*(\alpha)] = \sum_{r=0}^{N} r C_N^r p^r (1-p)^{N-r}$$

- Но нам не известна p.

Сглаживание: Good-Turing estimation

- Пусть n_r - количество n-грамм, которые встретились ровно r раз.
- Допустим, мы имеем s различных n-грамм $\alpha_1, ..., \alpha_s$, которые встречаются с вероятностями $p_1, ..., p_s$ соответственно.
- Тогда

$$E_N[n_r] = \sum_{i=1}^{s} P(c(\alpha_i = r)) = \sum_{i=1}^{s} C_N^r p_i^r (1 - p_i)^{N-r}$$

Сглаживание: Good-Turing estimation

- Нам не известны p_i, но у нас есть формула для $E_N[n_r]$, мы можем подсчитать n_r по корпусу и надеяться, что для небольших r выполнено $E_N[n_r] \approx n_r$.
- Так как нам известно конкретное количество вхождений r:

$$E_N[c^*(\alpha)|c(\alpha) = r] = N \sum_{i=1}^{s} p_i \frac{P(c(\alpha_i) = r)}{\sum_{j=1}^{s} P(c(\alpha_j) = r)}$$

так как каждая из s n-грамм может встречаться r раз и

$$P(\alpha = \alpha_i | c(\alpha) = r) = \frac{P(c(\alpha_i) = r)}{\sum_{j=1}^{s} P(c(\alpha_j) = r)}$$

Сглаживание: Good-Turing estimation

$$E_N[c^*(\alpha)|c(\alpha) = r] = \frac{N\sum_{i=1}^{s} p_i P(c(\alpha_i) = r)}{\sum_{j=1}^{s} P(c(\alpha_j) = r)}$$

- Знаменатель - $E_N[n_r]$ по определению.
- Раскроем скобки в числителе:

$$N\sum_{i=1}^{s} p_i P(c(\alpha_i) = r) = (r+1)\frac{N}{N+1}\sum_{i=1}^{s} C_{N+1}^{r} p_i^{r+1}(1-p_i)^{N-r} =$$

$$= (r+1)\frac{N}{N+1}E_{N+1}[n_{r+1}] \approx (r+1)E_{N+1}[n_{r+1}]$$

- Подставив всё в исходную формулу, получим:

$$r^* = E_N[c^*(\alpha)|c(\alpha) = r] = (r+1)\frac{E_{N+1}[n_{r+1}]}{E[n_r]}$$

- Можно сделать следующее допущение:

$$r^* = (r+1)\frac{n_{r+1}}{n_r}$$

- Как интерпретировать этот результат?

Сглаживание: Good-Turing estimation

- Интерпретация: давайте «перенесём» часть вероятности с n-грамм, которые встретились нам $r + 1$ раз, на n-граммы, которые встретились r раз.
- Как следствие, перенесём вероятность с n-грамм, которые встретились по одному разу, на ни разу не встречавшиеся n-граммы.
- Пусть n_r - количество n-грамм, встретившихся ровно r раз. Для каждого r необходимо вычислить

$$r^* = (r+1)\frac{n_{r+1}}{n_r}, \quad n_0 = N$$

- Тогда при $N = \sum_{r=0}^{\infty} r^* n_r = \sum_{r=1}^{\infty} r n_r$ будем иметь:

$$P_{GT}(t_i | t_{i-1} : c(t_{i-1} t_i) = r) = r^* / N$$

Сглаживание: Good-Turing estimation

Данный подход обладает рядом недостатков и сталкивается с некоторыми проблемами:

- Для больших r часто встречается ситуация $n_r = 0$.
- Для больших r, даже при отсутствии «дыр» в частотах, значения n_r достаточно зашумлены, ведь правильнее писать:

$$r^* = (r+1)\frac{E[n_{r+1}]}{E[n_r]}$$

- Но как вычислить математические ожидания?

Данные проблемы делают метод Good-Turing estimation неудобным для применения «как есть». Но он является фундаментом для построения других методов.

Сглаживание: Jelinek-Mercer interpolation

Допустим, $c(\text{мама мыла}) = 0$ и $c(\text{мама шыла}) = 0$ тогда:

- Рассмотренные до этого момента методы дадут одинаковый результат:

$$P(\text{мыла}|\text{мама}) = P(\text{шыла}|\text{мама})$$

- Что выглядит неправдаподобно, так как, очевидно, что:

$$P(\text{мыла}|\text{мама}) > P(\text{шыла}|\text{мама})$$

- Необходимо «смешать» биграммную и униграммную модели.

Сглаживание: Jelinek-Mercer interpolation

- Смесь моделей можно записать в виде:

$$P_{JM}(t_i|t_{i-1}) = \lambda_{t_{i-1}} P(t_i|t_{i-1}) + (1 - \lambda_{t_{i-1}}) P(t_i)$$

- $\lambda_{t_{i-1}}$ можно подобрать EM-алгоритмом, или, например, задать одинаковыми исходя из представлений о языковой модели. Но оптимальные значения должны быть связаны с контекстом t_{i-1}: для частого контекста - большие значения $\lambda_{t_{i-1}}$.
- Естественным рекурсивным образом распространяется на остальные n-граммные модели для $n \geq 2$.

Сглаживание: Katz smoothing

- Как и в методе Good-Turing, предлагается искусственно снизить частоты биграмм, которые встретились $r \geq 1$ раз, с помощью понижающего коэффициента d_r:

$$c_{katz}(t_{i-1}t_i) = d_{c(t_{i-1}t_i)}c(t_{i-1}t_i)$$

- Полученную массу необходимо распределить между биграммами, встретившимися 0 раз, в соответствии с языковой моделью предыдущего порядка (униграммной моделью):

$$c_{katz}(t_{i-1}t_i) = \alpha(t_{i-1})c(t_i)$$

Сглаживание: Katz smoothing

- Построенная модель будет иметь вид:

$$P_{katz}(t_i|t_{i-1}) = \frac{c_{katz}(t_{i-1}t_i)}{\sum_j c_{katz}(t_{i-1}t_j)}$$

- $\alpha(t_{i-1})$ вычисляются исходя из условия $\sum_i P_{katz}(t_i|t_{i-1}) = 1$:

$$\alpha(t_{i-1}) = \frac{1 - \sum_{i:c(t_{i-1}t_i)>0} P_{katz}(t_i|t_{i-1})}{\sum_{j:c(t_{i-1}t_i)=0} P(t_i)}$$

Сглаживание: Katz smoothing

Для вычисления d_r Katz предлагает следующий подход:

- Если $r > k$ (обычно $k = 5$), то будем считать, что сглаживание не требуется: $d_r = 1$.
- В остальных случаях потребуем соответствия модели Good-Turing:
  - $1 - d_r = \mu(1 - r^*/r)$ - «унесённая» масса пропорциональна соответствующей величине в Good-Turing.
  - $\sum_{r=1}^{k} n_r(1 - d_r)r = n_1$ - суммарная масса, перенесённая не неизвестные биграммы, такая же, как и в Good-Turing.

Сглаживание: Katz smoothing

- Подставив всё в исходную формулу, можно получить:

$$d_r = \frac{\frac{r^*}{r} - (k+1)\frac{n_{k+1}}{n_1}}{1 - (k+1)\frac{n_{k+1}}{n_1}}$$

- Аналогично Jelinek-Mercer, рекурсивно распространяется на n-граммные модели более высоких порядков.

Сглаживание: Witten-Bell smoothing

- Выпишем выражение для сглаживания Jelinek-Mercer:

$$P_{JM}(t_i|t_{i-1}) = \lambda_{t_{i-1}} P(t_i|t_{i-1}) + (1 - \lambda_{t_{i-1}}) P(t_i)$$

- Идея: $\lambda_{t_{i-1}}$ можно интерпретировать как вероятность использования модели более высокого порядка.
- Значит $1 - \lambda_{t_{i-1}}$ - вероятность встретить терм t_i в тестовых данных после терма t_{i-1}, при условии, что он не встречался в обучающей выборке в таком контексте.
- Эту вероятность можно оценить с помощью количества уникальных термов, встречавшихся после t_{i-1}.

Сглаживание: Witten-Bell smoothing

- Вычислим количество уникальных термов, встречавшихся после t_{i-1}:

$$N_{1+}(t_{i-1}\bullet) = |\{t_i : c(t_{i-1}t_i) > 0\}|$$

- Тогда выражение для $\lambda_{t_{i-1}}$ примет вид:

$$1 - \lambda_{t_{i-1}} = \frac{N_{1+}(t_{i-1}\bullet)}{N_{1+}(t_{i-1}\bullet) + \sum_j c(t_{i-1}t_j)}$$

Сглаживание: Absolute discounting

- Основано на общей с Jelinek-Mercer идее интерполяции моделей разных порядков.
- Но вместо вычисления $\lambda_{t_{i-1}}$ предлалается вычесть фиксированное $\delta \in [0, 1]$ из всех не нулевых количеств:

$$P_{abs}(t_i|t_{i-1}) = \frac{\max(c(t_{i-1}t_i) - \delta, 0)}{\sum_j c(t_{i-1}t_j)} + \frac{\delta N_{1+}(t_{i-1}\bullet)}{\sum_j c(t_{i-1}t_j)} P(t_i)$$

Сглаживание: Kneser-Ney smoothing

- Основано на модели Absolute discounting с более точным учётом модели низкого порядка: влияние модели низкого порядка должно быть тем больше, чем меньше количество вхождений в модели более высокого порядка.
- Введём обозначения:

$$N_{1+}(\bullet t_i) = |\{t_{i-1} : c(t_{i-1}t_i) > 0\}|$$

$$N_{1+}(\bullet\bullet) = \sum_i N_{1+}(\bullet t_i)$$

$$P_{KN}(t_i) = \frac{N_{1+}(\bullet t_i)}{N_{1+}(\bullet\bullet)}$$

Сглаживание: Kneser-Ney smoothing

Сведём всё воедино:

$$P_{KN}(t_i|t_{i-1}) = \frac{\max(c(t_{i-1}t_i) - \delta, 0)}{\sum_j c(t_{i-1}t_j)} + \frac{\delta N_{1+}(t_{i-1}\bullet)}{\sum_j c(t_{i-1}t_j)} P_{KN}(t_i)$$

Модификация данного подхода, заключающаяся в подборе отдельного δ для каждого n, является одним из лучших методов сглаживания.